

Fundamentos de Machine Learning Aplicados a Ingeniería Petrolera

Misael Edgar Zepeda Díaz

misael.zepeda@ingenieria.unam.edu

misa@queesia.com

+52 55 4280 4907



Universidad Nacional de Colombia
SPE Student Chapter



Este material forma parte de un curso impartido de manera presencial por Misael Edgar Zepeda Díaz

📍 Facultad de Minas – Universidad Nacional de Colombia, Medellín

📅 Fecha: 10 de octubre de 2025

🕒 Duración: 4 horas

🎓 Dirigido a estudiantes de la [Society of Petroleum Engineers \(SPE\) – UNALMED Student Chapter](#)

📌 Enfoque:
Aplicación de machine learning al análisis de reología de condensados y al modelado de viscosidad en ingeniería petrolera.

Este contenido forma parte de un programa de capacitación en inteligencia artificial aplicada a energía e ingeniería.

Para cursos, talleres o colaboraciones:

🌐 queesia.com

FUNDAMENTOS DE MACHINE LEARNING.

MSc. Misael Edgar Zepeda Díaz

📅 10 Octubre | 8:00 a 12:00 p.m.

🕒 **Duración:** 4 horas presencial

📍 **Facultad de Minas**

💰 **Inversión:** Gratis!!

INSCRÍBETE

UNIVERSIDAD NACIONAL DE COLOMBIA

Facultad de Minas
Sede Medellín

Contenido

- 1 ¿Qué es machine learning?
- 2 Aprendizaje supervisado
- 3 Aprendizaje no supervisado
- 4 Aprendizaje profundo

Evaluación inicial

20 minutos

Link: <https://forms.gle/PZrfPcAVZg1Nmbhr9>



MÓDULO 1

¿Qué es machine learning?

Misael Edgar Zepeda Díaz

misael.zepeda@ingenieria.unam.edu

misa@queesia.com

+52 55 4280 4907



Introducción y Objetivos

En este módulo introduciremos los [fundamentos del aprendizaje automático \(Machine Learning\)](#), su propósito, principales tipos y lenguaje común, utilizando ejemplos reales en el sector energético y datos experimentales de reología de condensados.

- ✓ Comprender qué es el machine learning y cómo difiere de la programación tradicional.
- ✓ Reconocer por qué se utiliza en ingeniería y en la industria energética.
- ✓ Identificar los principales tipos de aprendizaje (supervisado, no supervisado, por refuerzo).
- ✓ Familiarizarse con los términos esenciales para interpretar modelos y métricas.

¿Qué es Machine Learning?

"Campo de estudio que da a las computadoras la habilidad de aprender sin ser explícitamente programadas."

— Arthur Samuel, IBM, 1959


El machine learning es un enfoque que permite a las computadoras aprender **patrones** a partir de **datos** y generar predicciones o decisiones **sin instrucciones explícitas**.

En lugar de programar reglas específicas, mostramos **ejemplos** al sistema y permitimos que descubra por sí mismo **cómo resolver el problema**.



Programación Tradicional vs. Machine Learning

Programación tradicional



$$\mu = \frac{\tau}{\dot{\gamma}}$$

$$\tau = \dot{\gamma} * \mu$$


Datos + Reglas → Resultados

Requiere reglas explícitas

Limitado a lo programado

Difícil de adaptar a nuevos datos

Enfoque en Machine Learning



$$\tau = m * \dot{\gamma} + b$$


Datos + Resultados → Reglas (patrones)

Aprende patrones automáticamente

Puede generalizar a nuevos casos

Se adapta con nuevos datos

Inteligencia Artificial vs Machine Learning



Evolución Histórica del Machine Learning

Hitos Históricos

● Siglos XVIII-XIX

Fundamentos Estadísticos: Teorema de Bayes, 1763) y Método de los Mínimos Cuadrados, 1805) sientan las bases de los métodos de inferencia y regresión, esenciales para el ML moderno.

● 1943 -1950s

Primer computadora digital ENIAC (1945)

Neurona Artificial: Desarrollo del primer modelo matemático de una neurona biológica, un hito fundamental para las redes neuronales.
Test de Turing

● 1960s -1970s

Primer "invierno de la IA": expectativas no cumplidas y reducción de financiamiento
Primer microprocesador comercial (1971)

● 1980s

Avances: algoritmos de redes neuronales con retropropagación.

● 1987 - mediados de 1990s

Segundo "invierno de la IA": colapso de los sistemas expertos, pérdida de inversión y cierres de laboratorios

1990s (fin)

Consolidación del internet público (WWW)

Resurgimiento del ML: El enfoque se traslada de la IA basada en el conocimiento al ML orientado a los datos (data-driven).
Nuevos Algoritmos. Máquinas (SVM), Árboles de Decisión y técnicas de Ensemble (Bagging, Boosting)

2009 - presente

Boom del deep learning: avances en poder computacional, datos masivos y algoritmos

Primer iPhone (2007)

Factores del Boom Actual



Explosión de datos
disponibles

- Conectividad a Internet omnipresente.
- Avances en la tecnología de sensores.
- Dispositivos inteligentes y conectados.



Aumento del poder
computacional

- **Deep learning** ha hecho posible lo que antes parecía imposible.
- Incremento masivo en la potencia de cómputo (GPUs).
- Grandes conjuntos de datos etiquetados para entrenamiento.
- Avances en los algoritmos.



Avances algorítmicos

- **Presencia generalizada** de los modelos de *machine learning* en los productos y sistemas con los que interactuamos a diario.

¿Dónde encontramos ML?

Filtros de spam en correo electrónico

Recomendación de productos

Enrutamiento de correo mediante OCR
(reconocimiento óptico de caracteres)

Detección de fraude en tarjetas de crédito

 Todos

 Spam

85

 Papelera

Los clientes que vieron artículos en tu historial de búsqueda también vieron

Página 3 de 7 [Volver a empezar](#)



Jurassic World Hammond Collection Figura de Acción Coleccionable Velocíptero de 9.5 cm con 14 Puntos De...
★★★★★ 107
100+ comprados el mes pasado
\$19⁹⁹



Mattel, Jurassic World Dinosaurio de Juguete Carchosaurus Hammond Collection para niños de 8 años en adelante
★★★★★ 1422
3 ofertas desde
\$1,479⁹⁹



NOOZ Sunglasses polarized for Men and Women - 100% UV protection - with Compact Case - DINO Collection
★★★★★ 322
\$1,580⁰⁰



Clementoni 19576 Batman - Puzzle de 1000 Piezas, Colorido Juego de Habilidades para Toda la Familia, Rompecabezas...
★★★★★ 145
\$643⁷⁵
Recibido el **viernes, 1 de octubre**



Clementoni Baby Mickey Canta Carrigón - Disney. Juega y Aprende +6 Meses. Juguete de Peluche Que Ayuda al...
★★★★★ 122
\$1,099⁰⁰
Recibido el **sep 26 - 30**
Solo quedan 1 en stock.



Panasonic KX-TS108W - Teléfono con cable, color blanco.
★★★★★ 114
\$1,159⁴⁵
Envío GRATIS por Amazon México
No disponible por el...



Logitech G502 Hero Mouse Gaming con Cable G413 SE Teclado Mecánico Gaming en Inglés.
- 15% \$2,906⁰⁰
Recibido el **mañana, 23 de septiembre**
Envío GRATIS por Amazon México

Terminología Fundamental de Datos

Según la OECD (Glosario de términos estadístico), los **datos** son características o información, generalmente numérica, recolectada mediante observación.

Los Datos Vienen en Muchas Formas

Casi cualquier cosa puede ser convertida en números:

- Medidas
- Texto
- Imágenes
- Sonido
- Video

Los datos pueden tener diferentes relaciones:

- Relaciones espaciales
- Relaciones temporales


Tipos de Datos

No estructurados (80%)

Data Report
Data Report
Data Report
Data Report

Name	SAMPLE 1 S/C
Operator	Petroleum Analysis Company
Project	Viscosities Study
Instrument	Rheometer
Temperature	25 °C

Temperature °C	Shear Stress Pa	Shear rate 1/s	Viscosity Pa.s
25	1.612385929	2.51219	0.00146228
25	1.877067498	3.98155	0.00254542
25	2.425488876	6.31033	0.00340941
25.01	2.423630998	10.0012	0.00391292
25	1.949111124	15.8508	0.0042562
25	2.591051306	25.1219	0.0044856
25	2.523502181	39.8155	0.00462635
24.99	2.066302738	63.1033	0.00470366
24.99	2.287744195	100.012	0.00476611
25	2.31216999	158.508	0.00483542
25	3.73468	251.219	0.00491477
25	7.49728	398.155	0.00501633
25	7.74109	631.033	0.00513616
25.01	7.76909	1000.12	0.00526846



Estructurados (20%)

Adicionales

Del reporte

	A	D	E	F	G	H	I	J	K	L
	Identificador Tesis	Pozo	Temperatura Etiqueta [°C]	SC / CC	Velocidad de corte [1/s]	Esfuerzo de corte [Pa]	Temperatura experimental [°C]	Densidad [g/cm3]	°API	Viscosidad [cP]
1	Condensado 1 - 25°C	11	25	SC	2.51219	0.00367353	25	0.829	37.4	1.46228
2	Condensado 1 - 25°C	11	25	SC	3.98155	0.0101347	25	0.829	37.4	2.54542
3	Condensado 1 - 25°C	11	25	SC	6.31033	0.0215145	25	0.829	37.4	3.40941
4	Condensado 1 - 25°C	11	25	SC	10.0012	0.0391339	25.01	0.829	37.4	3.91292
5	Condensado 1 - 25°C	11	25	SC	15.8508	0.0674642	25	0.829	37.4	4.2562
6	Condensado 1 - 25°C	11	25	SC	25.1219	0.112687	25	0.829	37.4	4.4856
7	Condensado 1 - 25°C	11	25	SC	39.8155	0.1842	25	0.829	37.4	4.62635
8	Condensado 1 - 25°C	11	25	SC	63.1033	0.296816	24.99	0.829	37.4	4.70366
9	Condensado 1 - 25°C	11	25	SC	100.012	0.476668	24.99	0.829	37.4	4.76611
10	Condensado 1 - 25°C	11	25	SC	158.508	0.766454	25	0.829	37.4	4.83542
11	Condensado 1 - 25°C	11	25	SC	251.219	1.23468	25	0.829	37.4	4.91477
12	Condensado 1 - 25°C	11	25	SC	398.155	1.99728	25	0.829	37.4	5.01633
13	Condensado 1 - 25°C	11	25	SC	631.033	3.24109	25	0.829	37.4	5.13616
14	Condensado 1 - 25°C	11	25	SC	1000.12	5.26909	25.01	0.829	37.4	5.26846
15	Condensado 1 - 50°C	11	50	SC	1.00013	0.00209023	50	0.811	37.4	2.08996
16	Condensado 1 - 50°C	11	50	SC	1.58508	0.00344608	50	0.811	37.4	2.17407
17	Condensado 1 - 50°C	11	50	SC	2.51219	0.00573545	50.01	0.811	37.4	2.28305
18	Condensado 1 - 50°C	11	50	SC	3.98155	0.00970733	50	0.811	37.4	2.43808
19	Condensado 1 - 50°C	11	50	SC	6.31033	0.0165294	50	0.811	37.4	2.61941
20	Condensado 1 - 50°C	11	50	SC	10.0012	0.0263034	50.01	0.811	37.4	2.63002
21	Condensado 1 - 50°C	11	50	SC	15.8508	0.0415765	50.01	0.811	37.4	2.62298
22	Condensado 1 - 50°C	11	50	SC	25.1219	0.0670983	50	0.811	37.4	2.67091
23	Condensado 1 - 50°C	11	50	SC	39.8155	0.107314	50	0.811	37.4	2.69529
24	Condensado 1 - 50°C	11	50	SC	63.1033	0.171181	50	0.811	37.4	2.71272

Categorías de Datos

Discretos

Categóricos

Categóricos

Continuos

Otros

	A	D	E	F	G	H	I	J	K	L
1	Identificador Tesis	Pozo	Temperatura Etiqueta [°C]	SC / CC	Velocidad de corte [1/s]	Esfuerzo de corte [Pa]	Temperatura experimental [°C]	Densidad [g/cm3]	°API	Viscosidad [cP]
2	Condensado 1 - 25°C	11	25	SC	2.51219	0.00367353	25	0.829	37.4	1.46228
3	Condensado 1 - 25°C	11	25	SC	3.98155	0.0101347	25	0.829	37.4	2.54542
4	Condensado 1 - 25°C	11	25	SC	6.31033	0.0215145	25	0.829	37.4	3.40941
5	Condensado 1 - 25°C	11	25	SC	10.0012	0.0391339	25.01	0.829	37.4	3.91292
6	Condensado 1 - 25°C	11	25	SC	15.8508	0.0674642	25	0.829	37.4	4.2562
7	Condensado 1 - 25°C	11	25	SC	25.1219	0.112687	25	0.829	37.4	4.4856
8	Condensado 1 - 25°C	11	25	SC	39.8155	0.1842	25	0.829	37.4	4.62635
9	Condensado 1 - 25°C	11	25	SC	63.1033	0.296816	24.99	0.829	37.4	4.70366
10	Condensado 1 - 25°C	11	25	SC	100.012	0.476668	24.99	0.829	37.4	4.76611
11	Condensado 1 - 25°C	11	25	SC	158.508	0.766454	25	0.829	37.4	4.83542
12	Condensado 1 - 25°C	11	25	SC	251.219	1.23468	25	0.829	37.4	4.91477
13	Condensado 1 - 25°C	11	25	SC	398.155	1.99728	25	0.829	37.4	5.01633
14	Condensado 1 - 25°C	11	25	SC	631.033	3.24109	25	0.829	37.4	5.13616
15	Condensado 1 - 25°C	11	25	SC	1000.12	5.26909	25.01	0.829	37.4	5.26846
16	Condensado 1 - 50°C	11	50	SC	1.00013	0.00209023	50	0.811	37.4	2.08996
17	Condensado 1 - 50°C	11	50	SC	1.58508	0.00344608	50	0.811	37.4	2.17407
18	Condensado 1 - 50°C	11	50	SC	2.51219	0.00573545	50.01	0.811	37.4	2.28305
19	Condensado 1 - 50°C	11	50	SC	3.98155	0.00970733	50	0.811	37.4	2.43808
20	Condensado 1 - 50°C	11	50	SC	6.31033	0.0165294	50	0.811	37.4	2.61941
21	Condensado 1 - 50°C	11	50	SC	10.0012	0.0263034	50.01	0.811	37.4	2.63002
22	Condensado 1 - 50°C	11	50	SC	15.8508	0.0415765	50.01	0.811	37.4	2.62298
23	Condensado 1 - 50°C	11	50	SC	25.1219	0.0670983	50	0.811	37.4	2.67091
24	Condensado 1 - 50°C	11	50	SC	39.8155	0.107314	50	0.811	37.4	2.69529
25	Condensado 1 - 50°C	11	50	SC	63.1033	0.171181	50	0.811	37.4	2.71272

Series temporales

Organizados por orden de tiempo (precios de petróleo)

Observación/registro

Característica / Var. independiente

Variable dependiente

¿Qué es un Modelo de Machine Learning?

Un modelo de machine learning es una aproximación de la relación entre variables, expresada como:

$$Y = f(X) + \text{error}$$

Variables de entrada
(x)




Variables de salida
(y)


Donde **X** representa las variables de entrada (características)

Y es la variable de salida (target)

f es la función que el modelo aprende

error término que refleja el ruido irreducible de los datos como el posible sesgo del modelo.





Observaciones de datos de entrada (X)

F	G	I	J	K
SC / CC	Velocidad de corte [1/s]	Temperatura experimental [°C]	Densidad [g/cm3]	°API
SC	2.51219	25	0.829	37.4
SC	3.98155	25	0.829	37.4
SC	6.31033	25	0.829	37.4
SC	10.0012	25.01	0.829	37.4
SC	15.8508	25	0.829	37.4
SC	25.1219	25	0.829	37.4
SC	39.8155	25	0.829	37.4
SC	63.1033	24.99	0.829	37.4
SC	100.012	24.99	0.829	37.4
SC	158.508	25	0.829	37.4
SC	251.219	25	0.829	37.4
SC	398.155	25	0.829	37.4
SC	631.033	25	0.829	37.4
SC	1000.12	25.01	0.829	37.4
SC	1.00013	50	0.811	37.4
SC	1.58508	50	0.811	37.4
SC	2.51219	50.01	0.811	37.4
SC	3.98155	50	0.811	37.4
SC	6.31033	50	0.811	37.4
SC	10.0012	50.01	0.811	37.4
SC	15.8508	50.01	0.811	37.4
SC	25.1219	50	0.811	37.4
SC	39.8155	50	0.811	37.4
SC	63.1033	50	0.811	37.4

$$Y = f(X) + \text{error}$$



Predicciones del objetivo (y)

L
Viscosidad [cP]
1.46228
2.54542
3.40941
3.91292
4.2562
4.4856
4.62635
4.70366
4.76611
4.83542
4.91477
5.01633
5.13616
5.26846
2.08996
2.17407
2.28305
2.43808
2.61941
2.63002
2.62298
2.67091
2.69529
2.71272

Construcción de un modelo

Para crear un modelo definimos cuatro cosas:

1. Características y objetivo

Atributos o variables de entrada que describen los datos de salida

2. Algoritmo

Método matemático que define la estructura general del modelo. Actúa como una forma/Plantilla para el modelo.

3. Hiperparámetros

Configuraciones ajustables que controlan el comportamiento del algoritmo

4. Función de Pérdida

Métrica que cuantifica el error del modelo y que se busca minimizar. Se debe optimizar.

Entrenamos el modelo usando datos históricos:


- El algoritmo y los hiperparámetros proporcionan la forma general del modelo.
- Se “aprenden” los valores para el modelo que minimizan la función de pérdida.

Tipos de Machine Learning

Aprendizaje Supervisado

Aprendizaje No Supervisado

Aprendizaje por Reforzamiento



Predice un target a partir de datos etiquetados.

- **Clasificación:** Predice categorías
- **Regresión:** Predice valores numéricos

Ejemplos: Detección de spam, predicción de precios

Organiza datos según su estructura inherente.

- **Clustering:** Agrupa datos similares
- **Detección de anomalías:** Identifica outliers

Ejemplos: Segmentación de clientes, detección de fraudes


Aprende estrategias mediante interacción y recompensas.

- **Agente:** Toma decisiones
- **Entorno:** Proporciona recompensas

Ejemplos: Juegos (ajedrez, Go), robots autónomos


Aprendizaje supervisado vs no supervisado

Aprendizaje Supervisado



Aprendizaje supervisado vs no supervisado

Aprendizaje No Supervisado




Aprendizaje supervisado

Regresión vs Clasificación


Regresión

- Predice una o más variables objetivo **numéricas**. Ejemplos: precio de una casa, número de apagones eléctricos, demanda de un producto.



Clasificación

- Predice una **clase / categoría**, ya sea binaria o dentro de un conjunto. Ejemplos: detección de enfermedades pulmonares, identificación de tipos de plantas, análisis de sentimiento, detección de spam.



Aprendizaje no supervisado

Clustering vs Reducción de Dimensionalidad

Clustering (Agrupamiento)

- Agrupa datos no etiquetados en **conjuntos** según similitud.
- Objetivo: encontrar **patrones ocultos** o segmentos naturales.


Ejemplos: segmentación de clientes, detección de fraudes, agrupamiento de genes.

Reducción de Dimensionalidad


- Reduce el número de variables manteniendo la mayor información posible.
- Objetivo: **visualizar datos complejos** y eliminar ruido.

Ejemplos: análisis de componentes principales (PCA), t-SNE para visualizar datos en 2D.


Ejemplo de Clustering (K-Means)



Datos originales en 3D con clusters



Datos proyectados en 2D con PCA (clusters preservados)



¿Qué Puede y No Puede Hacer el Machine Learning?

Comprender las **capacidades y limitaciones** del machine learning es esencial para aplicarlo correctamente y establecer **expectativas realistas** sobre sus resultados.

Puede Hacer	No Puede Hacer
✓ Automatizar tareas directas Clasificación de correos, transcripción de audio, reconocimiento de imágenes	✗ Entender contexto Captar sarcasmo, humor o intenciones sutiles en comunicación
✓ Hacer predicciones Predecir demanda, precios, comportamiento de usuarios basado en patrones históricos	✗ Determinar causación Identificar si A causa B o solo están correlacionados (ej: ventas de helado y crímenes)
✓ Personalizar servicios Recomendaciones de productos, contenido adaptado a preferencias individuales	✗ Explicar por qué ocurren las cosas Proporcionar explicaciones causales de fenómenos complejos
✓ Detectar patrones complejos Identificar relaciones no obvias en grandes volúmenes de datos	✗ Proponer soluciones Determinar el impacto de intervenciones o sugerir cómo resolver problemas

***Dada la cantidad y calidad suficiente de datos**

El machine learning identifica patrones y correlaciones, pero no determina causas ni explica por qué existen esos patrones.

Adopción y Éxito de la IA en Empresas (Estudios MIT y BCG, 2024-2025)

Boston Consulting Group (BCG)

- *AI Adoption in 2024: 74 % of Companies Struggle to Achieve and Scale Value*
- **Solo 26 % de las compañías** han pasado de pruebas de concepto a valor de negocio real.
- Fuente: [AI Adoption in 2024: 74% of Companies Struggle to Achieve and Scale Value | BCG](#)

Massachusetts Institute of Technology (MIT)

- Informe 2025 citado por medios:
- **95 % de los pilotos** de IA generativa en empresas no generan retorno medible.
- Causas principales: integración deficiente, falta de talento y gobernanza.
- Fuente: <https://fortune.com/2025/08/18/mit-report-95-percent-generative-ai-pilots-at-companies-failing-cfo>

Resumen del Módulo

Puntos Clave Aprendidos

-  Machine learning permite a las computadoras aprender de datos **sin programación explícita**
-  Existen tres tipos principales: supervisado, no supervisado y por reforzamiento
-  La terminología de datos es fundamental para comunicarse efectivamente en proyectos de ML
-  Un modelo es una aproximación matemática que relaciona variables de entrada y salida
-  ML tiene capacidades poderosas pero también limitaciones importantes que debemos entender

Próximo Módulo

En el siguiente módulo, profundizaremos en el proceso de modelado de machine learning y discutiremos los pasos clave para construir y entrenar un modelo de machine learning.



Módulo 2: Modelado

MÓDULO 2

Aprendizaje Supervisado

Misael Edgar Zepeda Díaz

misael.zepeda@ingenieria.unam.edu

misa@queesia.com

+52 55 4280 4907



Qué veremos

Predecir viscosidad μ [cP] con velocidad de corte (γ) y temperatura experimental (T_{exp}).

- ✓ EDA mínima (μ vs γ en log-log, por T).
- ✓ Regresión: Lineal, Cuadrática/Polinómica, Logarítmica, Potencial, k-NN, Random Forest.
- ✓ Clasificación (SC vs CC): Logística, Árbol, k-NN.
- ✓ Perillas clave: grado (polinomio), k (k-NN), profundidad (árbol/RF), uso de T_{exp} .
- ✓ Pérdida/Métricas: MSE (entrenamiento); R^2 y MAE (regresión), Accuracy/F1/ROC-AUC/PR-AUC (clasificación).
- ✓ Evaluación honesta: GroupKFold por muestra.
- ✓ Demos 3 casos por algoritmo: bajo $\rightarrow$ mejorado $\rightarrow$ “óptimo didáctico”.

Al final podrás...

- ✓ Elegir el modelo adecuado para μ .
- ✓ Saber qué mover (grado, k, profundidad, etc.) y cómo leer R^2 /MAE.
- ✓ Entender el impacto de T_{exp} y por qué la ley de potencia suele ajustarse mejor.
- ✓ Explicar una clasificación SC/CC con métricas operativas y ajuste de umbral.


Acceso al código

- ✓ <https://queesia.com/blog/post.html?slug=ml-reologia-condensados>
- https://colab.research.google.com/drive/1svNIK77sKDpW_-v71Vkb3coUMx95EOt4?usp=sharing




Análisis Exploratorio de Datos Mínimo

EDA (Exploratory Data Analysis) es el paso de reconocer el terreno antes de modelar: revisamos la calidad, el rango y la forma de los datos para decidir transformaciones y anticipar qué modelos pueden funcionar.

Distribución de Viscosidad μ [cP] — Antes de Podar



Curvas de viscosidad antes de quitar valores atípicos



Curvas de viscosidad después de quitar valores atípicos








Diagrama de caja y bigotes (box plot) antes y después de quitar valores atípicos

Viscosidad por Temperatura — Antes de Podar



Viscosidad por Temperatura — Después de Podar



Resumen Descriptivo y Calidad de los Datos

	columna	tipo	count	%missing	unique	top	freq	mean	std	min	25%	50%	75%	max
0	Identificador Tesis	cat	2569.000000	0.00%	178.000000	Condensado 1 - 50°C	16.000000	nan	nan	nan	nan	nan	nan	nan
1	Identificador IMP	cat	2569.000000	0.00%	178.000000	Cibix - 1001 - 25°C - CC	16.000000	nan	nan	nan	nan	nan	nan	nan
2	Campo	cat	2569.000000	0.00%	6.000000	Ixachi	841.000000	nan	nan	nan	nan	nan	nan	nan
3	Pozo	cat	2569.000000	0.00%	13.000000	M2	336.000000	nan	nan	nan	nan	nan	nan	nan
4	T_label	cat	2569.000000	0.00%	3.000000	80	860.000000	nan	nan	nan	nan	nan	nan	nan
5	SC / CC	cat	2569.000000	0.00%	2.000000	CC	1288.000000	nan	nan	nan	nan	nan	nan	nan
6	Velocidad de corte [1/s]	num	2569.000000	0.00%	nan	nan	nan	184.264	280.033	1.000	10.001	39.816	251.219	1000.120
7	Esfuerzo de corte [Pa]	num	2569.000000	0.00%	nan	nan	nan	0.521	0.916	0.000	0.018	0.100	0.599	6.328
8	Viscosidad [cP]	num	2569.000000	0.00%	nan	nan	nan	2.557	1.198	0.048	1.638	2.341	3.326	6.985
9	Temperatura experimental [°C]	num	2569.000000	0.00%	nan	nan	nan	51.726	22.508	24.960	25.000	50.000	80.000	80.230
10	Densidad [g/cm3]	num	2426.000000	5.57%	nan	nan	nan	0.806	0.019	0.751	0.791	0.807	0.823	0.841
11	°API	num	2426.000000	5.57%	nan	nan	nan	38.337	2.133	35.279	36.952	37.981	38.837	44.824

Regresión

Regresión en μ : Lineal

¿Qué hace?

Ajusta una relación **lineal** para predecir la **viscosidad (μ)** a partir de **velocidad de corte (y)** y **temperatura (T)**, optimizada con **SGD** para observar la evolución de la pérdida y las métricas por época.

Setup

- **Objetivo (y)**: Viscosidad μ [cP]
- **Variables (X)**: Velocidad de corte [1/s], Temperatura experimental [°C]
- **Validación**: GroupKFold por *Identificador Tesis*
- **Preprocesado**: StandardScaler (pipeline)

Hiperparámetros

Épocas: las que recorre train_with_sgd (80)

Métricas reportadas (validación)

R^2 (más alto = mejor)

MAE [cP] y **RMSE [cP]** (más bajo = mejor)

Gráficas

- Curvas por época: **MSE (train)**, **MAE (valid)**, **R^2 (valid)**
- **Real vs. Predicho (valid)** con R^2 , MAE, RMSE + **línea ideal $y=x$**




- Cuadro con **coeficientes (β)** en espacio **escalado**

Cómo leer el resultado

- **Bien**: MAE $\downarrow$ y R^2 $\uparrow$ hasta estabilizar; nube cerca de la diagonal.
- **Si falla**: R^2 bajo/MAE alto sostenido $\Rightarrow$ el modelo lineal **sin densidad** no capta la forma; considerar añadir densidad o un modelo no lineal.

SGD: Descenso de Gradiente Estocástico (SGD) es un algoritmo de optimización en aprendizaje automático

StandardScaler: feature a media 0 y desviación estándar 1



Regresión en μ : Lineal

¿Qué hace?

Predice la **viscosidad (μ)** como combinación lineal de **velocidad de corte (y)** y **temperatura (T)**. Se entrena con **SGD** para ver la evolución de **MSE (train)**, **MAE (valid)** y **R^2 (valid)** a lo largo de **80** épocas.

Setup

Objetivo (y): μ [cP]

Variables (X): y [1/s], T [°C]

Validación: **GroupKFold** por *Identificador Tesis*

Preprocesado: **StandardScaler**

Hiperparámetros

Optimizador: SGDRegressor(loss="squared_error",
learning_rate="invscaling", eta0=0.01)

Épocas: 80

Métricas reportadas (validación)

R^2 (más alto = mejor)

MAE [cP] y **RMSE [cP]** (más bajo = mejor)

Gráficas

Curvas por época: **MSE (train)**, **MAE (valid)**, **R^2 (valid)**

Real vs. Predicho (valid) con R^2 , MAE, RMSE + línea ideal **$y=x$**




Cuadro con **coeficientes (β)** en espacio **escalado**

Cómo leer el resultado

Bien: MAE $\downarrow$ y R^2 $\uparrow$ hasta estabilizar; nube cerca de la diagonal.

Si falla: R^2 bajo/MAE alto $\Rightarrow$ lineal **sin densidad** no capta la forma; considerar **añadir densidad** o un modelo no lineal.

Regresión en μ : Lineal



Regresión en μ : Cuadrática

¿Qué hace?

Amplía el lineal añadiendo **términos cuadráticos** e **interacciones** entre **y , T , ρ** para capturar **curvatura**:
 γ , T , ρ , γ^2 , T^2 , ρ^2 , γT , $\gamma \rho$, $T \rho$.

Setup

Objetivo (y): μ [cP]

Variables (X): γ [1/s], T [°C], ρ [g/cm³]

Preprocesado: PolynomialFeatures(degree=2, include_bias=False) → **StandardScaler**

Entrenador: SGD con **80** épocas

Validación: GroupKFold por *Identificador Tesis*

Hiperparámetros

Transformación: PolynomialFeatures(**degree=2**)

Optimizador: SGDRegressor(loss="**squared_error**",
learning_rate="invscaling", eta0=0.01)

Épocas: 80

Métricas reportadas (validación)

R^2 , MAE [cP], RMSE [cP]

Gráficas

Curvas por época: **MSE (train)**, **MAE (valid)**, **R^2 (valid)**

Real vs. Predicho (valid) con R^2 , MAE, RMSE + **$y=x$**





Resumen de **# de términos** y **coeficientes (β)** en **escala estándar**

Cómo leer el resultado

Bien: mejora sobre el lineal ($\downarrow$ MAE, $\uparrow R^2$) al capturar curvatura/interacciones.

Si falla: posible **sobreajuste** o ruido; considerar **regularización L2** o comparar con **modelo potencial** ($\log \mu$).

Regresión en μ : Cuadrática



$$\mu = \beta_0 + \beta_1\gamma + \beta_2T + \beta_3\rho + \beta_4\dot{\gamma}^2 + \beta_5T^2 + \beta_6\rho^2 + \beta_7\gamma T + \beta_8\gamma\rho + \beta_9T\rho$$

Regresión en μ : Polinomio grado 4

¿Qué hace?

Modelo **de términos hasta grado 4** (potencias e interacciones) de **y, T, ρ** . Se entrena con **SGD** y mostramos la evolución de **MSE (train)**, **MAE (valid)** y **R^2 (valid)**.

Setup

Objetivo (y): μ [cP]

Variables (X): γ [1/s], T [°C], ρ [g/cm³]

Preprocesado: PolynomialFeatures(degree=4, include_bias=False) → **StandardScaler**

Validación: GroupKFold por *Identificador Tesis*

Hiperparámetros

Transformación: PolynomialFeatures(**degree=4**, include_bias=False)

Optimizador: SGDRegressor(loss="**squared_error**", **learning_rate**="invscaling", eta0=0.01, power_t=0.5)

Épocas: **100** (según el código de esta celda)

Métricas reportadas (validación)

R^2 (↑ mejor)

MAE [cP] y **RMSE [cP]** (↓ mejor)

Gráficas

Curvas por época: **MSE (train)**, **MAE (valid)**, **R^2 (valid)**





Real vs. Predicho (valid) con **R^2** , **MAE**, **RMSE** + **línea ideal $y=x$**

Resumen de **# de términos** (muy alto en grado 4) y **coeficientes (β)** en **escala estandarizada**

Cómo leer el resultado

- MAE ↓ y R^2 ↑ hasta estabilizar; nube cerca de la diagonal.

Regresión en μ : Polinomio grado 4



Regresión en μ : Logaritmo

Aplica una **transformación logarítmica a las variables predictoras** (y', T, ρ) con $\log_{10}(x) = \ln(x+1)$ y luego ajusta un **modelo lineal** con **SGD**. La idea es **linealizar relaciones multiplicativas** y **reducir asimetría/varianza** en las features antes del ajuste.

Setup

Objetivo (y): μ [cP]

Variables (X): γ [1/s], T [°C], ρ [g/cm³]

Preprocesado: `FunctionTransformer(np.log1p)` → `StandardScaler()`

Validación: `GroupKFold` por *Identificador Tesis*

Hiperparámetros

Transformación: $\log_{10}$ en X (seguro si hay ceros)

Optimizador: `SGDRegressor(loss="squared_error", learning_rate="invscaling", eta0=0.01, power_t=0.5)`

Épocas: 100 (loop con `partial_fit`)

Métricas reportadas (validación)

R^2 (↑ mejor)

MAE [cP] y **RMSE [cP]** (↓ mejor)

Gráficas que mostramos

Curvas por época: **MSE (train)**, **MAE (valid)**, **R^2 (valid)**

Real vs. Predicho (valid) con R^2 , MAE, RMSE + **línea**


$y=x$

Coefficientes β (en **espacio transformado y estandarizado**)




Cómo leer el resultado

- MAE ↓ y R^2 ↑ hasta estabilizar; nube cerca de la diagonal.




Regresión en μ : Logaritmo



$$\mu = \beta_0 + \beta_1 \ln(\gamma) + \beta_2 \ln(T) + \beta_3 \ln(\rho)$$







Regresión en μ : Potencial



$$\mu = \beta_0 * \gamma^{\beta_1} + T^{\beta_2} + \rho^{\beta_3}$$

Regresión en μ : Exponencial



$$\mu = \beta_0 * e^{\beta_1\gamma + \beta_2 T + \beta_3 \rho}$$

Tabla Comparativa de Rendimiento de Modelos

	R2	MAE	RMSE
Potencial	0.7879	0.4369	0.5851
Exponencial	0.7602	0.4492	0.6222
Polinómico Gr. 4	0.7465	0.4915	0.6397
Cuadrático	0.7129	0.5176	0.6808
Logarítmico	0.6853	0.5321	0.7127
Lineal	0.6562	0.5473	0.7450

KNN μ : Regresión

¿Qué hace?

Predice la **viscosidad (μ)** promediando (con pesos por **distancia**) los valores de los **k** puntos de entrenamiento **más cercanos** a cada observación en el espacio (γ, T, ρ). No asume forma funcional; aprende por **proximidad**.

Setup

- **Objetivo (y):** μ [cP]
- **Variables (X):** γ [1/s], T [°C], ρ [g/cm³]
- **Validación:** **GroupKFold (5)** por *Identificador Tesis* usando `cross_val_predict`
- **Preprocesado:** **StandardScaler** (esencial: la distancia es sensible a la escala)

Hiperparámetros

- **k** (`n_neighbors`): **3, 5, 10, 20** (probados en la celda)
- **weights:** "distance" (vecinos cercanos pesan más que los lejanos)
- **métrica de distancia:** Euclídea (por defecto, tras estandarizar)

Métricas reportadas (validación)

- **R²** ($\uparrow$ mejor)
- **MAE [cP]** y **RMSE [cP]** ($\downarrow$ mejor)

Gráficas





- Dispersión **Real vs. Predicho** para cada **k** con línea **y=x**
- **Tabla comparativa** de R², MAE y RMSE para **k** $\in$ {3,5,10,20} (gradientes de color)

Cómo leer el resultado

- **Bien:** mejora clara sobre lineal y cuadrático ($\downarrow$ MAE, $\uparrow$ R²) **sin degradarse en validación.**

(Si empeora al subir $k \rightarrow$ exceso de suavizado; si k muy chico $\rightarrow$ sobreajuste por ruido.)

KNN μ : Regresión



	R2	MAE	RMSE
k			
20	0.7452	0.4178	0.6123
10	0.7165	0.4399	0.6458
5	0.6542	0.4757	0.7133
3	0.5971	0.4992	0.7699

Random Forest Regressor

¿Qué hace?

Construye muchos **árboles de decisión** sobre *submuestras* del train y promedia sus predicciones. Reduce **varianza** y captura **no linealidades** e **interacciones** sin requerir ingeniería de términos polinómicos.

Setup

Objetivo (y): Viscosidad [cP]

Variables (X): Velocidad de corte [1/s], Temperatura experimental [°C], Densidad [g/cm³], °API (*si existe*)

Split: 70% train / 30% test (hold-out, random_state=42)

Validación en train: KFold(5, shuffle=True, rs=42) vía GridSearchCV

Preprocesado: StandardScaler() en pipeline (*RF no lo necesita, pero no afecta*)

Hiperparámetros (buscados en GridSearchCV, solo en TRAIN 70%)

n_estimators: [50, 100, 200]

max_depth: [5, 10, 20, None]

Métricas reportadas

En CV (train 70%): mean_train_score y mean_test_score (R^2) + **Brecha** (Sobreaajuste)

OOF en TRAIN: R^2 con cross_val_predict (generalización dentro del 70%)

TEST (30% nunca visto): R^2 , R^2_{adj} , MAE [cP], RMSE [cP], MAPE [%] (*si no hay y=0*), SMAPE [%]

Gráficas que mostramos

Predicho vs Real — OOF en TRAIN (CV)

Predicho vs Real — **TEST (30%)** con cuadro de hiperparámetros y métricas

Residuos vs Predicho — TEST

Histograma de residuos — TEST

Tabla CV (heat/gradients): n_estimators × max_depth con R^2 validación, R^2 entrenamiento y Brecha



Bien: mejora clara sobre lineal/cuadrático/k-NN ($\downarrow$ MAE, $\uparrow$ R^2) **sin degradarse en TEST;** brecha de sobreajuste pequeña.

(*Si hay brecha grande: sube n_estimators y limita max_depth; si sub-ajusta: aumenta max_depth o features útiles.*)

Random Forest Regressor

Hiperparámetros: Profundidad y Estimadores

Profundidad Máx.	Nº Estimadores	R² Validación (CV)	R² Entrenamiento	Brecha (Sobreajuste)
8	20.0000	0.9218	0.9889	0.0671
11	200.0000	0.9216	0.9888	0.0672
7	20.0000	0.9210	0.9885	0.0675
10	100.0000	0.9209	0.9885	0.0677
6	20.0000	0.9183	0.9882	0.0698
9	50.0000	0.9180	0.9882	0.0702
5	10.0000	0.9095	0.9754	0.0659
4	10.0000	0.9092	0.9751	0.0659
3	10.0000	0.9073	0.9745	0.0672
1	5.0000	0.8328	0.8743	0.0415
2	5.0000	0.8326	0.8743	0.0417
0	5.0000	0.8316	0.8741	0.0426



30% en set de validación

Clasificación

Regresión logística

¿Qué hace?

Modela la probabilidad de que una muestra sea **CC (1)** frente a **SC (0)** como una **combinación lineal** de variables numéricas y categóricas, pasada por una **función sigmoide**. Permite **ajustar el umbral** para priorizar sensibilidad o precisión.

Setup

Objetivo (y): SC / CC $\rightarrow$ target_numeric (SC=0, CC=1)

Variables numéricas: Velocidad de corte [1/s], Densidad [g/cm³], Temperatura experimental [°C], °API, Viscosidad [cP]

Variables categóricas: Campo, Pozo

Partición: 70% **train** / 30% **test** con **estratificación** por y

Preprocesado (ColumnTransformer):

Numéricas $\rightarrow$ StandardScaler()

Categóricas $\rightarrow$ OneHotEncoder(handle_unknown='ignore')

Hiperparámetros

Modelo: LogisticRegression(max_iter=1000, random_state=42)

solver: lbfgs (por defecto)

penalty: l2 (por defecto)

C: 1.0 (regularización)

Métricas reportadas

Accuracy (umbral 0.5)

Matriz de confusión + **classification_report**
(precision/recall/F1 por clase)

ROC-AUC

PR-AUC (Precisión-Recall)

Gráficas que mostramos

Matriz de confusión (umbral 0.5)

Curva ROC con AUC

Curva Precisión-Recall con AUC

Cómo leer el resultado

Bien: mejora clara frente a azar/baseline

(ROC-AUC $\gg$ 0.5, PR-AUC alto) **sin**

degradarse al ajustar el umbral; matriz con pocos FN/FP (según lo que priorices).




Regresión logística

--- 1. Preparación de Datos ---

numeric_features = ['Velocidad de corte [1/s]', 'Densidad [g/cm3]', 'Temperatura experimental [°C]', '°API', 'Viscosidad [cP]']

categorical_features = ['Campo', 'Pozo']

target = 'SC / CC'



KNN Campo petrolero: Clasificación

¿Qué hace?

Clasifica el **Campo** de una muestra comparándola con sus **k vecinos más cercanos** en el plano (**°API, Viscosidad**) y asignando la **clase mayoritaria**. Aprende por **proximidad**; no impone forma funcional.

Setup

Objetivo (y): Campo (multiclase)

Variables (X): °API, Viscosidad [cP]

Partición: 75% **train** / 25% **test** con **estratificación** por Campo

Preprocesado: **StandardScaler** (clave: la distancia depende de la escala)

Hiperparámetros

k (n_neighbors): 3, 5, 10, 20 (*probados*)

weights: uniform (por defecto del clasificador en tu código actual)

métrica de distancia: Euclídea (implicada por KNN tras escalar)

Métricas reportadas

Accuracy en test (para cada k)

Classification report del **mejor k** (precision, recall, F1 por clase)

Gráficas que mostramos

Rendimiento vs k (línea con marcador y punto rojo en el mejor k)

Matriz de confusión (mejor k)

Tabla comparativa de Accuracy por k (gradiente de color)

Cómo leer el resultado


Bien: **accuracy** alto y **confusión** concentrada en la diagonal, **sin** degradarse al subir/bajar k.

(Si k muy pequeño → *sobreajuste*; si k muy grande → *sobre-suavizado* y *pérdida de fronteras*).

KNN Campo petrolero: Clasificación


Campo (API, Viscosidad)

K=3



Reporte de Clasificación para k=3:

	precision	recall	f1-score	support
Cibix	0.77	0.73	0.75	167
Ixachi	0.72	0.71	0.72	175
Qesqui	0.69	0.77	0.73	129
Racemosa	0.60	0.50	0.55	24
Valeriana	1.00	1.00	1.00	24
Valeriana-Racemosa	0.89	0.89	0.89	98
accuracy			0.76	617
macro avg	0.78	0.77	0.77	617
weighted avg	0.76	0.76	0.76	617



Árbol de decisión

¿Qué hace?

Aprende **reglas de decisión** jerárquicas que particionan el espacio ($\gamma, \nu, T, \rho, \mu, \text{°API}$) para **predecir CC (1) vs SC (0)**. Captura **interacciones y no linealidades** de forma interpretable (reglas tipo *si-entonces*).

Setup

Objetivo (y): SC / CC $\rightarrow$ binaria (SC=0, CC=1)

Variables (X): Velocidad de corte [1/s], Temperatura experimental [°C], Densidad [g/cm³], Viscosidad [cP], °API

Partición: 70% **train** / 30% **test** (estratificada)

Preprocesado: *(no requiere escalado)*

Hiperparámetros (en este experimento)

max_depth = 5

random_state = 42

(Sugerencia para grid rápido: max_depth $\in \{3, 4, 5, 6, 8\}$)

Métricas reportadas

Accuracy (umbral 0.5)

ROC-AUC, PR-AUC

Classification report (precision/recall/F1 por clase)

Gráficas que mostramos

Matriz de confusión (test)

Curva ROC + AUC

Curva Precisión-Recall + AUC

Árbol aprendido (nodos con clases y pureza)

Cómo leer el resultado




Bien: mejora clara frente a baseline ($\uparrow$ ROC-AUC/PR-AUC) **sin degradarse en test**; matriz con pocos FN/FP y árbol compacto (profundidad moderada).

Árbol de decisión

CC / SC (Velocidad de corte, Temperatura, Densidad, Viscosidad, °API)

Modelo: DecisionTreeClassifier

Hiperparámetro: profundidad máxima = 5



MÓDULO 3

Aprendizaje no supervisado

Misael Edgar Zepeda Díaz

misael.zepeda@ingenieria.unam.edu

misa@queesia.com

+52 55 4280 4907



Objetivos

- ✓ Clustering: agrupar datos similares
- ✓ Reducción de dimensionalidad: simplificar los datos

K-means

¿Qué hace?

Agrupar las muestras en **k clústeres** minimizando la **distancia intra-grupo** en el espacio ($T, \rho, \mu^{\circ API}$). No usa etiquetas: descubre **patrones** y **segmentos** en los datos.

Setup

Variables (X): Temperatura experimental [°C], Densidad [g/cm³], Viscosidad [cP], °API

Etiqueta de referencia (no usada para agrupar): Campo (para análisis posterior)

Preprocesado: StandardScaler() (esencial en clustering por distancia)

Dimensionalidad para visualización: PCA(n_components=2)

Hiperparámetros (en este experimento)

KMeans(n_clusters=5, random_state=42, n_init=10)

PCA(n_components=2, random_state=42)

Métricas reportadas

Silhouette promedio (global)

Silhouette por clúster (gráfico en bandas)

Tabla cruzada: Cluster vs. Campo (consistencia con la realidad)

Gráficas

Silhouette por clúster con línea del **promedio**

PCA 2D coloreado por:




Cluster (k-means), 2) Campo (verdad), 3) °API, 4) Temperatura, 5) Densidad, 6) Viscosidad

Tabla cruzada Cluster × Campo (como tabla en notebook)



Cómo leer el resultado

Bien: **Silhouette** moderado/alto (picos positivos y bandas compactas), **PCA** con clústeres **separables**, y **tabla cruzada** con **dominancia clara** de ciertos Campos por clúster (no necesariamente 1-a-1, pero sí patrones).

K-means



K-means



DBSCAN

¿Qué hace?

Agrupa puntos donde la **densidad local** supera un umbral y deja como **ruido** (etiqueta = -1) los puntos aislados. A diferencia de k-means, **no** asume clústeres esféricos ni requiere fijar k.

Setup

X (numéricas): Temperatura experimental [°C], Densidad [g/cm³], Viscosidad [cP], °API

Referencia externa (no usada para agrupar): Campo (para validar en tabla cruzada)

Preprocesado: StandardScaler() (indispensable en métodos basados en distancia)

Reducción p/visualizar: PCA(n_components=2, random_state=42)

Hiperparámetros (en tu código)

min_samples = 5 → densidad mínima para “núcleo”
eps:

Estimación automática vía **k-dist plot** (rodilla) → eps_opt ≈ rodilla detectada

Luego fijado manualmente: eps_opt = 0.5 (*sugerencia: probar ambos y comparar*)

Salidas/Métricas que reporta

clústeres detectados y % de **ruido**

Tabla cruzada Cluster DBSCAN × Campo (coherencia con la “verdad”)

Gráficas que mostramos

k-distancia con **rodilla** marcada (guía para eps)

PCA 2D coloreado por:

Cluster DBSCAN (incluye ruido -1)

Campo (verdad)

°API y Temperatura (gradientes físicos)

Cómo leer el resultado


Bien: pocos “ruidos” (-1) y clústeres compactos/estables que **correlacionan** con “Campo” en la **tabla cruzada**.

Si hay demasiado ruido → sube eps gradualmente (p. ej. +0.05) o baja min_samples.





Si todo es un solo clúster → baja eps o sube min_samples.

Si los clústeres se mezclan en PCA → revisa *scaling*, transforma variables (p. ej., log(μ)), o agrega/quita features.

DBSCAN



Análisis Visual Completo de DBSCAN (eps=0.50)



MÓDULO 4

Aprendizaje profundo

Misael Edgar Zepeda Díaz

misael.zepeda@ingenieria.unam.edu

misa@queesia.com


+52 55 4280 4907




Objetivos

- ✓ Red neuronal
- ✓ Red neuronal recurrente

Recordando los datos



2019



Red neuronal

¿Qué hace?

Ajusta una función **no lineal** $\mu = f(\gamma, T, \rho)$ aprendiendo pesos en capas densas. Captura **interacciones** y **no linealidades** que los modelos lineales no toman.

Setup

Objetivo (y): Viscosidad [cP]

Variables (X): Velocidad de corte [1/s], Temperatura experimental [°C], Densidad [g/cm^3]

Split: train_test_split(test_size=0.2, random_state=42)

Preprocesado: StandardScaler() en X (crítico en redes)

Hiperparámetros (en este experimento)

Arquitectura: Input(3) → Dense(64, relu) → Dense(64, relu) → Dense(1)

Optimizador: Adam (lr $\approx 1e-3$ por defecto)

Pérdida: MSE • **Métrica:** MAE

Épocas: 100 • **Batch:** 32 (implícito)

(Opcional para clase: EarlyStopping(patience=10, restore_best_weights=True); L2=1e-4 o Dropout 0.1-0.2)

Métricas reportadas

R², MAE [cP], RMSE [cP] en test

Curvas de entrenamiento: **loss (MSE)** y **MAE** en train/val

Gráficas

Curvas por época: loss(MSE) y MAE (train vs. val)

Real vs. Predicho (test) con línea ideal $y = xy$ caja con R²/MAE/RMSE

Cómo leer el resultado

Bien: val_loss y val_MAE ↓ y se **estabilizan**; nube cerca de $y = x$; **R² ↑**, **MAE/RMSE ↓**.


Sobreaajuste: loss(train) ↓ pero val_loss ↑/oscila; nube se abre; gap grande train-val.

Subajuste: ambas curvas altas/planas; R² bajo; nube muy dispersa.


Red neuronal

Viscosidad (v,T,d)

Curvas de Aprendizaje de la Red Neuronal





Rendimiento de la Red Neuronal — Real vs. Predicho





Red neuronal (SC / CC)

Viscosidad (v,T,d, SC/CC)



Red neuronal (SC / CC y Campo)

Viscosidad (v,T,d)



Red neuronal recurrente

¿Qué hace?

Predice μ [cP] **por paso** aprendiendo dependencias temporales de la curva reológica con **LSTM** (salida *time-distributed*).

Setup

y: μ por timestep

X (3D): (muestras, pasos, features)

Dinámicas: $\dot{\gamma}$ (y opcionalmente μ_{t-1})

Estáticas replicadas: T, ρ , °API

Split: 80/20 · **Escalado:** StandardScaler · **Mask:** ignora padding ($\dot{\gamma} > 0$)

Arquitectura

Input $\rightarrow$ LSTM(64, rs=True) $\rightarrow$ LSTM(64, rs=True) $\rightarrow$
TimeDistributed(Dense(1))

Hiperparámetros (experimento)

Adam · **loss:** MSE · **épocas:** 50 · **batch:** 8

Métricas



$R^2 \uparrow$ · MAE/ RMSE [cP] $\downarrow$ · curvas loss/val_loss

Gráficas

Curvas de entrenamiento (MSE/MAE) · **Real vs Predicho** en **log-log** con línea identidad





Red neuronal recurrente

Viscosidad (v,T,d)






Red neuronal recurrente (SC/CC)

Viscosidad (v,T,d)



Red neuronal recurrente (SC/CC) + Campo

Viscosidad (v,T,d)





Universidad Nacional de Colombia
SPE Student Chapter



Misael Edgar Zepeda Díaz
misael.zepeda@ingenieria.unam.edu
misa@queesia.com
[+52 55 4280 4907](tel:+525542804907)
www.queesia.com